

**CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA PAULA SOUZA**

**Faculdade de Tecnologia de Santana de Parnaíba**

**Curso Superior de Tecnologia em Ciência de Dados**

**VICTOR RIBEIRO CUNHA**

**GUSTAVO HENRIQUE MOISES MARTINS**

**SANTANA DE PARNAÍBA**

**2025**

VICTOR RIBEIRO CUNHA  
GUSTAVO HENRIQUE MOISES MARTINS

**PREVISÃO DE CRISES HÍDRICAS EM SÃO PAULO POR MEIO DA INFERÊNCIA  
DE DADOS**

Trabalho de Graduação apresentado à  
Faculdade de Tecnologia de Santana de  
Parnaíba como requisito parcial para a  
obtenção do título de Tecnólogo em  
Ciência de Dados, sob a orientação do  
Professor Inacio Henrique Yano

**SANTANA DE PARNAÍBA**  
**2025**

VICTOR RIBEIRO CUNHA  
GUSTAVO HENRIQUE MOISES MARTINS

**PREVISÃO DE CRISES HÍDRICAS EM SÃO PAULO POR MEIO DA INFERÊNCIA  
DE DADOS**

Aprovado pelos membros da banca examinadora em  
\_\_\_\_/\_\_\_\_/\_\_\_\_ com menção \_\_\_\_ (\_\_\_\_\_).

Banca Examinadora

---

---

---

**SANTANA DE PARNAÍBA  
2025.**

*“Existe apenas um bem, o conhecimento, e um mal, a ignorância.”*

*- Sócrates*

## RESUMO

A intensificação das mudanças climáticas e o crescimento populacional acelerado têm agravado a ocorrência de crises hídricas em diversas regiões do mundo, inclusive no Brasil. Mesmo sendo um país com abundantes recursos hídricos, o Brasil enfrenta desafios crescentes relacionados à gestão e ao uso sustentável da água. Antecipar a ocorrência dessas crises é fundamental para minimizar seus impactos sociais e ambientais. Este trabalho propõe o desenvolvimento de uma aplicação web para previsão de crises hídricas no Sistema Cantareira, em São Paulo, utilizando técnicas de aprendizado de máquina aplicadas a dados climáticos históricos do INMET (2003 a 2024). Foram avaliados três algoritmos de classificação em três horizontes de previsão (30, 60 e 90 dias). Os resultados indicam capacidade discriminativa modesta no horizonte de 30 dias (AUC-ROC entre 0,68 e 0,70), sem precisão operacional, atribuída à escassez de eventos históricos rotulados. A aplicação web desenvolvida em Streamlit disponibiliza os resultados por meio de gráficos e indicadores interativos, funcionando como protótipo funcional da metodologia proposta.

**Palavras-chave:** Crises hídricas. Previsão climática. Machine Learning. Aplicação web. Gestão de recursos hídricos.

## ABSTRACT

The intensification of climate change and accelerated population growth have exacerbated the occurrence of water crises in various regions around the world, including Brazil. Despite being a country with abundant water resources, Brazil faces growing challenges related to the management and sustainable use of water. Anticipating the occurrence of these crises is essential to minimize their social and environmental impacts. This work proposes the development of a web application for forecasting water crises in the Cantareira System, in São Paulo, using machine learning techniques applied to historical climate data from INMET (2003 to 2024). Three classification algorithms were evaluated across three prediction horizons (30, 60 and 90 days). The results indicate modest discriminative capacity at the 30-day horizon (AUC-ROC between 0.68 and 0.70), without operational precision, attributed to the scarcity of labeled historical events. The web application developed in Streamlit presents the results through interactive charts and indicators, functioning as a functional prototype of the proposed methodology.

**Keywords:** Water crises. Climate forecasting. Machine learning. Web application. Water resource management.

## SUMÁRIO

|                                                                      |    |
|----------------------------------------------------------------------|----|
| 1 INTRODUÇÃO .....                                                   | 9  |
| 1.1 Justificativa .....                                              | 9  |
| 1.2 Objetivo Geral .....                                             | 10 |
| 1.3 Objetivos Específicos .....                                      | 10 |
| 1.4 Problemática .....                                               | 10 |
| 2 REVISÃO BIBLIOGRÁFICA .....                                        | 11 |
| 2.1 Crises Hídricas .....                                            | 11 |
| 2.1.1 Precipitação e padrões de precipitação .....                   | 12 |
| 2.2 Previsão Climática e <i>Machine Learning</i> .....               | 13 |
| 2.2.1 Técnicas tradicionais versus Modelos de Machine Learning ..... | 13 |
| 2.3 Aplicações Web na Gestão Climática .....                         | 14 |
| 3 METODOLOGIA DE PESQUISA E MÉTODO TÉCNICO .....                     | 15 |
| 3.1 Processo de Análise dos Dados .....                              | 16 |
| 3.2 CRISP-DM .....                                                   | 16 |
| 3.3 Pré-Processamento e engenharia de features .....                 | 17 |
| 3.3.1 Coleta e características da base .....                         | 18 |
| 3.3.2 Limpeza e padronização .....                                   | 18 |
| 3.3.3 Engenharia de <i>features</i> .....                            | 19 |
| 3.3.4 Rotulagem ( <i>labeling</i> ) dos dados .....                  | 21 |
| 3.3.5 Metodologia de Treinamento dos Modelos .....                   | 23 |
| 3.4 Ferramentas Utilizadas .....                                     | 26 |
| 3.5 Modelo EAP do projeto .....                                      | 27 |
| 3.6 Casos de Uso da Aplicação Web e Design Prévios .....             | 29 |
| 3.6.1 Caso uso de acesso .....                                       | 29 |
| 3.6.2 Modelo da página de login .....                                | 30 |
| 3.6.3 Caso de uso – criação de análise .....                         | 30 |
| 3.6.5 Caso de uso – resultados da análise .....                      | 32 |
| 3.6.7 Implementação final da interface .....                         | 33 |
| 3.7 Divulgação dos Resultados .....                                  | 34 |
| 4 ANÁLISE E RESULTADOS .....                                         | 34 |

|                                                    |    |
|----------------------------------------------------|----|
| 4.1 Desempenho comparativo dos modelos .....       | 34 |
| 4.2 Efeito da otimização do <i>threshold</i> ..... | 36 |
| 4.3 Importância das variáveis .....                | 36 |
| 4.4 Discussão dos resultados .....                 | 38 |
| 5 CONCLUSÃO.....                                   | 41 |
| REFERÊNCIAS.....                                   | 43 |

## 1 INTRODUÇÃO

Caracteriza-se uma crise hídrica com base na insuficiência do abastecimento de água para atender, em volume e qualidade, às necessidades de consumo humano em determinada região (ABCON SINDCON, 2023), contudo, esse fator é condicionado por mudanças climáticas, consumo inadequado em larga escala e falhas estruturais nos sistemas de abastecimento e tratamento. Esse fenômeno, que ocorre em diversas partes do mundo, tende a se agravar, o que torna essencial o desenvolvimento de mecanismos de previsão. A presente pesquisa tem como objetivo identificar formas de antecipar a ocorrência de crises hídricas por meio da análise de dados em São Paulo

Segundo UNESCO (2023), aproximadamente 46% dos habitantes do planeta não possuem serviços de saneamento seguros, e cerca de 26% da população não possui acesso à água potável, o que representa, respectivamente, 3,6 bilhões e 2 bilhões de pessoas.

Cerca de 20% de toda a água que flui da terra aos oceanos estão centralizadas no Brasil, paralelamente a isso, apenas dois terços do volume do Rio Amazonas, poderiam suprir a demanda hídrica global, de acordo com o IPEA (2022). Mesmo sendo um país provido da maior quantidade de água doce do mundo, o Brasil ainda possui crises em relação à falta de água. Diante desse cenário, torna-se imprescindível o desenvolvimento de ferramentas preditivas capazes de antecipar tais crises, com o intuito de possibilitar ações preventivas e mitigadoras, reduzindo os impactos sociais e ambientais decorrentes da falta de água.

### 1.1 Justificativa

As mudanças climáticas têm intensificado a ocorrência de crises hídricas, exigindo soluções tecnológicas que sejam flexíveis, acessíveis e adaptáveis a diferentes realidades regionais. A construção de uma aplicação web permitirá a ampliação do acesso a ferramentas preditivas, sem necessidade de softwares especializados, facilitando o uso em comunidades, prefeituras e instituições de pesquisa. Além disso, a solução poderá evoluir para integração automática com APIs de dados climáticos, tornando o sistema ainda mais dinâmico e atualizado.

## **1.2 Objetivo Geral**

Construir uma aplicação web que receba dados climáticos, utilize um modelo preditivo para avaliar o risco de crises hídricas e apresente os resultados de forma acessível e dinâmica.

## **1.3 Objetivos Específicos**

- Coletar e preparar dados climáticos históricos e atuais.
- Desenvolver um modelo de Machine Learning capaz de prever o risco de crise hídrica.
- Criar uma interface web amigável para entrada e consulta de dados.
- Exibir os resultados em gráficos e indicadores interativos.
- Possibilitar futuras integrações com APIs de dados climáticos em tempo real.

## **1.4 Problemática**

A ausência de soluções que permitam a entrada de dados locais e o processamento em tempo real dificulta a antecipação de crises e a adoção de medidas preventivas eficazes.

## 2 REVISÃO BIBLIOGRÁFICA

A presente seção tem como objetivo apresentar o referencial teórico que fundamenta esta pesquisa, abordando os principais conceitos relacionados às crises hídricas, técnicas de previsão climática baseadas em aprendizado de máquina e o papel das aplicações web na visualização e interpretação de dados meteorológicos. O levantamento bibliográfico busca embasamento em autores e estudos que contribuam para a construção metodológica e prática da proposta de modelagem e previsão de crises hídricas.

### 2.1 Crises Hídricas

As crises hídricas constituem um problema crescente e recorrente, configurando-se quando a demanda por água supera a disponibilidade real ou quando a água existe, mas apresenta qualidade inadequada para o uso. Isso tudo é agravado por fatores como o crescimento das cidades sem planejamento, mudanças no clima e a gestão ineficiente dos recursos hídricos (MEDEIROS et al., 2017). Para acompanhar essas situações, alguns indicadores vêm sendo muito usados, como o Índice de Severidade de Seca de Palmer (PDSI) e o Índice Padronizado de Precipitação (SPI), que ajudam a medir desvios nos padrões normais de chuva e umidade do solo (WELLS et al., 2004; McKEE et al., 1993).

Segundo previsão da Unesco (2015), até 2050 o mundo contará com cerca de 10 bilhões de habitantes, dos quais 70% podem enfrentar deficiência no abastecimento de água potável se as condições atuais forem mantidas. A preocupação se agrava com os impactos diretos das mudanças climáticas: o ano de 2024 foi o mais quente no Brasil desde 1961 (INMET, 2025), ampliando a pressão sobre sistemas de abastecimento já sobrecarregados. É nesse contexto que se insere a proposta desta pesquisa.

A encíclica *Laudato Si* ressalta que 'o acesso à água potável e segura é um direito humano essencial, fundamental e universal, porque determina a sobrevivência das pessoas e, portanto, é condição para o exercício dos outros direitos humanos' (PAPA FRANCISCO, 2015). A preocupação ética dialoga com dados concretos: a população brasileira cresceu substancialmente nas últimas décadas (IBGE, 2025), acentuando conflitos no uso dos recursos hídricos.

O *Intergovernmental Panel on Climate Change* alerta que o aquecimento global tem elevado, progressivamente, a temperatura média da atmosfera, gerando impactos socioambientais de larga escala (IPCC, 2014). Esses dados reforçam a necessidade de ferramentas tecnológicas flexíveis e acessíveis para gestão de crises, como a proposta deste trabalho.

A legislação brasileira, como o Decreto n. 24.643/1934 (Código das Águas) e a Lei n. 9.433/1997 (Política Nacional de Recursos Hídricos), já reconhece o uso prioritário da água para consumo humano e dessedentação animal em situações de escassez. A proposta desta aplicação respeita esse preceito e se coloca como instrumento auxiliar no planejamento e tomada de decisão.

A literatura reforça a urgência da inovação tecnológica no enfrentamento das crises hídricas. Galvão e Bermann (2015) discutem os conflitos pelo uso múltiplo da água, enquanto Tundisi (2008) alerta para os desafios do futuro. Selborne (2001) e Galizoni e Ribeiro (2011) ampliam o debate ao abordar o papel das normas éticas e comunitárias.

### **2.1.1 Precipitação e padrões de precipitação**

A previsão de crises hídricas a partir de dados meteorológicos requer a compreensão de duas grandezas fundamentais: a precipitação e seus padrões de distribuição. A precipitação (P) é definida como a queda de qualquer forma de água condensada da atmosfera sobre a superfície terrestre, sendo a principal fonte de realimentação de rios, reservatórios e lençóis freáticos. É expressa em milímetros (mm), unidade na qual 1 mm corresponde a 1 litro de água distribuído sobre um metro quadrado de superfície. Sua medição é realizada por pluviômetros, instrumentos que acumulam e quantificam o volume total de água precipitada em um local e período determinados.

Os padrões de precipitação (N), por sua vez, referem-se à distribuição espacial e temporal, à intensidade e à frequência das chuvas em uma determinada região. Tais padrões são condicionados por processos atmosféricos de larga escala, pela temperatura da superfície, pela topografia local e pela disponibilidade de umidade. A análise desses padrões é central para o monitoramento hídrico: quando a evapotranspiração supera de forma sustentada os índices de precipitação, configura-

se um déficit hídrico, condição diretamente associada ao agravamento de situações de escassez e, consequentemente, de crises hídricas.

## 2.2 Previsão Climática e *Machine Learning*

Para os fins deste trabalho, adota-se a definição clássica de aprendizado de máquina proposta por Mitchell (1997, p. 2), segundo a qual um programa de computador "aprende com a experiência E em relação a uma classe de tarefas T e uma medida de desempenho P, se seu desempenho nas tarefas em T, medido por P, melhora com a experiência E". Em termos práticos, isso significa que, em vez de serem explicitamente programados com regras fixas, os modelos de aprendizado de máquina identificam padrões a partir de dados históricos e os utilizam para realizar previsões sobre dados novos. No contexto deste estudo, a experiência E corresponde à série histórica de dados climáticos do INMET, a tarefa T é a classificação de um período como pré-crise ou normal, e a medida de desempenho P é avaliada por métricas como o F1-score e a AUC-ROC, detalhadas na seção 3.3.5.

Nos últimos anos, técnicas de *machine learning* (aprendizado de máquina) têm ganhado destaque na previsão de eventos climáticos. A ideia é treinar modelos com dados históricos, como séries de precipitação, temperatura, umidade etc., e fazer previsões com base nisso. Modelos como regressão linear, redes neurais, árvores de decisão e *random forest* têm mostrado resultados promissores nesse tipo de tarefa (AHMED et al., 2020; YASEEN et al., 2021). Diferente dos métodos estatísticos mais tradicionais, esses modelos conseguem lidar melhor com relações não lineares e padrões mais complexos entre os dados. Além disso, o uso de dados de sensoriamento remoto e APIs meteorológicas (como do INMET ou da NOAA) tem deixado as previsões mais completas e úteis em escala regional.

### 2.2.1 Técnicas tradicionais versus Modelos de Machine Learning

Presentemente, a previsão numérica do tempo (NWP) é essencial para a previsão do tempo, pois fornece informações valiosas acerca de ameaças climáticas, além de corroborar para o gerenciamento de riscos. Modelos de circulação geral (GCMs) são utilizados para NWP, estes combinam a representação numérica de última geração da dinâmica dos fluidos atmosféricos e outros processos físicos, como

transferência radiativa e processos de nuvem. Entretanto, os GCMs possuem deficiências importantes, as quais incluem parametrizações físicas imperfeitas, custo operacional alto etc. (WEYN; DURRAN; CARUANA, 2019).

No entanto, uma questão básica permanece: o ML pode produzir previsões meteorológicas puramente estatísticas aprendendo com observações meteorológicas passadas sem nenhuma informação explícita sobre a física atmosférica, aprendendo assim a emular efetivamente os processos físicos da atmosfera? Com várias décadas de dados meteorológicos confiáveis de observações de satélite, software de código aberto amplamente disponível e computação eficiente em unidades de processamento gráfico, a previsão do tempo usando ML e, especificamente, NNs profundos, está se tornando cada vez mais viável (WEYN; DURRAN; CARUANA, 2019).

Scher (2018) adotou uma abordagem distinta, que consistiu em emular diretamente a dinâmica de um GCM a partir do seu estado atmosférico; em outras palavras, o pesquisador treinou uma rede neural para reproduzir o comportamento de um GCM ao longo do tempo. O modelo, contudo, representava um "clima" mais limitado, por não incorporar processos do mundo real, como a sazonalidade. Posteriormente, em pesquisa que buscou contornar essa limitação, Scher e Messori (2019) constataram que reproduzir o clima de modelos que incluem o ciclo sazonal permanece desafiador, em contraste com os resultados promissores obtidos em modelos sem sazonalidade. O desempenho das redes foi mais severamente degradado em entradas de alta resolução, evidenciando que a complexidade do clima real, mais do que o custo computacional, constitui o principal obstáculo. Ainda assim, tais resultados contribuíram para o avanço das previsões meteorológicas globais baseadas em aprendizado de máquina (WEYN; DURRAN; CARUANA, 2019).

## **2.3 Aplicações Web na Gestão Climática**

Com o volume crescente de dados meteorológicos disponíveis em tempo real, surge também a necessidade de criar ferramentas que ajudem a visualizar e interpretar essas informações. Com base nesse contexto, são desenvolvidas aplicações web, que combinam uma interface acessível com funcionalidades de análise. Ferramentas feitas com tecnologias como JavaScript, Python (com Django ou

Flask), e bibliotecas de visualização como D3.js, Leaflet ou Highcharts, permitem a criação dashboards completos, com mapas, gráficos e alertas personalizados. Isso tudo é útil não só para pesquisadores, mas também para órgãos públicos e produtores rurais, o que possibilita a tomada de decisão baseada em dados (SILVA et al., 2022; WORLD BANK, 2020).

Um exemplo de sistema criado, é o “SIRHTO”, uma plataforma web construída com *HTML*, *PHP*, *JavaScript* e *CSS* integrada a um banco de dados relacional, a qual tem o objetivo de gerenciar e integrar informações relacionadas aos recursos hídricos do estado de Tocantins, sobretudo, visa atender as necessidades de monitoramento, planejamento e tomada de decisões estratégicas, ao consolidar dados em uma plataforma web acessível (BATISTA; FRANCIEL; LENNON, 2025). Para isso foi utilizada uma *API HidroWeb*, da Agência Nacional de Águas (ANA). A plataforma possibilita a sincronização automática de dados relativos à precipitação, nível e vazão dos rios, dados que são fornecidos pelas estações telemétricas do estado em questão, ademais a aplicação fornece relatórios hidrometeorológicos por via de automações (BATISTA; FRANCIEL; LENNON, 2025).

### 3 METODOLOGIA DE PESQUISA E MÉTODO TÉCNICO

Esta pesquisa se ancora metodologicamente em quatro pilares: a abordagem aplicada, o caráter exploratório, a natureza descritiva e a intenção explicativa. Trata-se de uma investigação aplicada porque visa oferecer uma solução prática, uma aplicação web, voltada à previsão de crises hídricas em regiões com alto risco de escassez. Ao mesmo tempo, assume caráter exploratório ao investigar um problema cuja complexidade demanda compreensão ampliada das interações entre clima, população e infraestrutura.

É descritiva porque busca representar as características do fenômeno por meio da coleta e organização de dados climáticos e hidrológicos; e explicativa por propor a identificação de fatores causais associados às crises hídricas e avaliar a eficácia de modelos preditivos. A natureza quantitativa da pesquisa também se destaca, dada a manipulação e análise de grandes volumes de dados meteorológicos, oriundos de fontes como INMET, *WorldClim* e *NASA POWER*.

### 3.1 Processo de Análise dos Dados

Utilizou-se neste trabalho o modelo CRISP-DM (*Cross Industry Standard Process for Data Mining*), como base de auxílio ao processamento dos dados. Esse modelo trata-se de um framework consolidado em projetos de mineração de dados


Os dados foram retirados das bases do INMET a qual disponibiliza algumas métricas como: Precipitação (chuvas) – pluviômetros, satélite; Temperatura – média, mínima/máxima; Índice de vegetação (NDVI) – reflete secas; Volume de reservatórios; Nível de rios; Uso da água por setor (agricultura, doméstico etc.); Índice de aridez (ou evapotranspiração/potencial hídrico); PDI; SPI

Esses campos foram observados e modelados e, por conseguinte, utilizados como base para o treinamento de um modelo de inteligência capaz de prever crises hídricas.

### 3.2 CRISP-DM

Em prelúdio, esse modelo funciona com base em seis etapas, o que possibilita o desenvolvimento do projeto de forma mais organizada e eficiente, como representado na figura 1:

Figura 1: Fluxo de funcionamento do CRISP-DM



Fonte: Adaptado de Chapman et al. (2000).

O CRISP-DM tem como objetivo padronizar as técnicas de análise de dados utilizadas em um projeto. A estrutura das seis fases, anteriormente citadas, tem como finalidade lidar com a complexidade dos dados, em outras palavras, o método funciona mesmo como um facilitador de processos, de modo a garantir que cada etapa esteja alinhada com os objetivos propostos do projeto (SHEARER, 2000). Além disso o método corrobora para a identificação de padrões importantes dentro de uma base de dados, a fim de contribuir para resultados satisfatórios.

Em síntese, a primeira etapa, entendimento do negócio, fundamenta-se em entender os objetivos dos estudos e quais perguntas a análise buscará responder. Em seguida, a fase de Entendimento dos dados busca identificar características relevantes, inconsistências e dados que possam estar ausentes. Por conseguinte, a preparação dos dados, dedica-se ao tratamento dos dados brutos, como limpeza, seleção de variáveis, ajuste de formato entre outros fatores. Na fase de Modelagem, aplicam-se uma série de técnicas de *Machine Learning* e algoritmos estatísticos, a fim de extrair padrões significativos. Vale ressaltar que algumas dessas técnicas exigem formatos específicos dos dados, reforçando a necessidade de um preparo durante as etapas anteriores (CHAPMAN et al, 2000).

A etapa de Avaliação, objetiva verificar se modelos construídos de fato respondem às questões levantadas pela pesquisa, de forma a assegurar a precisão, robustez e relevância. Por fim, a fase de implantação consiste em organizar e apresentar os resultados por meio de relatórios, visualizações gráficas ou documentação detalhada

### **3.3 Pré-Processamento e engenharia de features**

As etapas descritas a seguir correspondem às fases de Entendimento dos Dados e Preparação dos Dados do modelo CRISP-DM, anteriormente apresentado na seção 3.2. A construção da base de dados utilizada neste estudo seguiu um *pipeline* estruturado de três etapas: coleta e caracterização da base bruta, limpeza e padronização dos registros, e engenharia de *features* derivadas. Cada etapa foi implementada como um *script* independente em Python, permitindo rastreabilidade e reprodutibilidade do processo.

### 3.3.1 Coleta e características da base

Os dados utilizados foram obtidos do Instituto Nacional de Meteorologia (INMET), por meio do portal de dados históricos, considerando o período de 2003 a 2024. A escolha do INMET como fonte primária se justifica pela qualidade institucional, padronização das séries históricas e disponibilidade pública dos registros horários.

Os arquivos foram baixados em formato XLSX, organizados por ano e contendo registros horários das estações meteorológicas localizadas no estado de São Paulo. Após a unificação e processamento, a base resultante contemplou um total de 8.036 dias de observações contínuas, distribuídas ao longo de aproximadamente 22 anos.

As variáveis brutas coletadas incluem precipitação total horária, temperatura do ar (média, máxima e mínima), umidade relativa, pressão atmosférica, radiação global, velocidade do vento e rajada máxima. Em razão da ausência de identificador padronizado de estação meteorológica nos arquivos do INMET, optou-se por uma agregação global para o estado de São Paulo, sem distinção por estação individual. Essa abordagem representa uma limitação reconhecida do estudo, podendo ser refinada em trabalhos futuros com desagregação por estação.

### 3.3.2 Limpeza e padronização

A etapa de limpeza foi implementada no *script* `run_ints_xlsx.py`, responsável por consolidar os arquivos brutos em uma base única, tratável e tecnicamente íntegra. As principais operações realizadas foram:

- Unificação dos arquivos. Todos os arquivos XLSX foram lidos sequencialmente e concatenados em uma única estrutura tabular, preservando as colunas originais e adicionando metadados de origem (nome do arquivo e planilha) para rastreabilidade.
- Construção do *timestamp*. As colunas originais de data e hora foram unificadas em uma única variável temporal no padrão UTC (*Coordinated Universal Time*, ou Tempo Universal Coordenado), permitindo ordenação cronológica precisa e operações temporais consistentes ao longo do *dataset*. Registros com *timestamps* inválidos ou ausentes foram descartados.

- Conversão numérica. Os valores numéricos no padrão brasileiro (vírgula como separador decimal) foram convertidos para o padrão internacional (ponto), permitindo o processamento adequado pelas bibliotecas Python utilizadas.
- Tratamento de valores ausentes. O INMET utiliza o código -9999 para indicar ausência de leitura em suas estações automáticas. Esses valores foram identificados e convertidos para o tipo NaN (*Not a Number*), permitindo seu tratamento adequado nas etapas subsequentes.
- Sanitização da umidade relativa. Valores fora do intervalo fisicamente possível (0% a 100%) foram convertidos para NaN, eliminando registros inconsistentes que comprometeriam o cálculo de *features* derivadas.
- Controle de qualidade (*Quality Check*). Ao final do processo, foi gerada uma tabela auxiliar de QC com a proporção de valores ausentes por ano e por variável, permitindo a inspeção da integridade dos dados antes da etapa seguinte.

O resultado dessa etapa foi um arquivo no formato Parquet (inmet\_sp\_hourly\_clean.parquet), escolhido por sua eficiência em armazenamento e velocidade de leitura em *pipelines* de dados.

### 3.3.3 Engenharia de *features*

A engenharia de *features* foi realizada no *script* run\_features.py, responsável por transformar os dados horários em uma representação diária enriquecida com variáveis derivadas. Essas variáveis foram concebidas para capturar padrões hidrológicos relevantes para a previsão de crises hídricas, tendo como referência teórica os índices consolidados na literatura climatológica (MCKEE; DOESKEN; KLEIST, 1993; FRICH et al., 2002).

Agregação temporal (hora para dia). Como o objetivo do modelo é prever crises com horizonte de 30, 60 e 90 dias, a granularidade horária se mostrou desnecessariamente fina. A agregação diária foi realizada com funções estatísticas específicas para cada variável: soma para precipitação e radiação, média para temperatura, umidade e pressão, e máximo para rajada de vento. Essa escolha

respeita a natureza física de cada grandeza, a precipitação acumula ao longo do dia, enquanto a temperatura é representada por seu comportamento médio.

Features de precipitação acumulada (P7, P15, P30, P90). Foram criadas janelas móveis de 7, 15, 30 e 90 dias, representando a precipitação acumulada nos períodos imediatamente anteriores a cada dia. A escolha de múltiplas escalas temporais é justificada pela natureza multiescalar dos fenômenos hidrológicos: P7 captura eventos pluviais recentes, P30 representa o acúmulo mensal, e P90 evidencia tendências trimestrais. Crises hídricas tipicamente resultam de déficits acumulados em médio e longo prazo, sendo essas variáveis fundamentais para sua identificação precoce.

Features de sequência seca (DRY\_STREAK). Foi calculada a sequência atual de dias consecutivos com precipitação inferior a 1 mm, limiar amplamente adotado na literatura climatológica para caracterizar dias secos (FRICH et al., 2002), armazenada na variável DRY\_STREAK\_CUR. Adicionalmente, foram computados os valores máximos dessa sequência em janelas de 30 e 90 dias (DRY30\_MAX e DRY90\_MAX). A inclusão dessas variáveis se justifica pelo fato de que a distribuição temporal da chuva é tão relevante quanto seu volume acumulado: 30 mm distribuídos uniformemente em 30 dias representa um regime hidrológico distinto de 30 mm concentrados em um único evento seguido de seca prolongada. Sequências secas indicam estresse hidrológico real, reconhecidamente associado ao agravamento de crises hídricas.

Médias móveis de temperatura, umidade e pressão. Foram geradas médias móveis de 7 e 30 dias para temperatura (TMEAN\_MA7, TMEAN\_MA30) e umidade (URMEAN\_MA7, URMEAN\_MA30), além de uma média móvel de 7 dias para pressão atmosférica (PRESSAO\_MED\_MA7). A utilização de médias móveis suaviza variações diárias de curto prazo e evidencia tendências mais consistentes do regime climático, uma temperatura elevada em um dia isolado tem significado distinto de uma temperatura sustentada acima da média ao longo de 30 dias, que pode indicar um período de anomalia térmica relevante para o balanço hídrico.

SPI30 aproximado (SPI30\_APRX). O Índice Padronizado de Precipitação (SPI), proposto por McKee, Doesken e Kleist (1993) e recomendado pela Organização Meteorológica Mundial (OMM), é amplamente utilizado em estudos de monitoramento de secas por sua capacidade de quantificar o desvio da precipitação acumulada em

relação à climatologia local. Neste estudo, foi implementada uma versão aproximada do SPI de 30 dias (SPI30\_APRX), calculada como o escore-z (z-score) mensal da precipitação acumulada de 30 dias (P30), utilizando como referência a média e o desvio-padrão mensal de toda a série histórica disponível. Valores fortemente negativos indicam déficit pluviométrico em relação ao esperado para o mês, enquanto valores positivos indicam excedente, conforme a interpretação clássica do índice (MCKEE; DOESKEN; KLEIST, 1993). Cabe ressaltar que a implementação aqui adotada constitui uma aproximação metodológica do SPI clássico, sem ajuste de distribuição gama, configurando uma limitação reconhecida do estudo.

Ao final dessa etapa, foram obtidas 22 variáveis preditoras, consolidadas no arquivo `inmet_sp_daily_features.parquet`, que serviu como base para a etapa de rotulagem e treinamento dos modelos.

### 3.3.4 Rotulagem (*labeling*) dos dados

Após a engenharia de *features*, foi necessário definir a variável-alvo que o modelo aprenderá a prever. Para problemas de aprendizado supervisionado, essa etapa é fundamental: a qualidade dos rótulos determina o que o modelo é capaz de aprender. A estratégia adotada neste estudo consistiu em rotular cada dia da série histórica de acordo com a proximidade temporal de uma crise hídrica documentada, configurando uma abordagem de previsão de pré-evento. A implementação foi realizada no *script* `run_labels_pre_evento.py`.

Identificação dos eventos de crise. Foram considerados três períodos de crise hídrica documentados no estado de São Paulo, selecionados a partir da literatura acadêmica e de fontes institucionais reconhecidas:

- Crise de 2003–2004: período de nível crítico no Sistema Cantareira, com forte estiagem na região metropolitana de São Paulo.
- Crise de 2014–2015: evento de maior severidade já registrada no Sistema Cantareira, com volume útil abaixo de 10% e amplamente documentado na literatura científica (MARENGO et al., 2015; ANA, 2015).
- Crise de 2021: estiagem prolongada associada a alerta interinstitucional emitido por ANA, INMET, INPE e CEMADEN (ABES-SP, 2021).

Esses eventos foram consolidados em um arquivo estruturado (eventos.csv) contendo o nome do sistema hídrico, a data de início, a data de término e o critério de identificação da crise. A escolha de múltiplos eventos visa fornecer ao modelo exemplos diversos de padrões pré-crise, evitando que ele se especialize em um único episódio histórico.

Definição dos horizontes de previsão. O objetivo central do modelo é antecipar a ocorrência de uma crise hídrica com tempo hábil para a tomada de decisão por gestores públicos. Para isso, foram definidos três horizontes de previsão: 30, 60 e 90 dias, representados pelas variáveis-alvo  $y_{30}$ ,  $y_{60}$  e  $y_{90}$ , respectivamente. Cada variável é binária e indica, para um dado dia da série, se haverá ocorrência de crise nos próximos 30, 60 ou 90 dias.

Lógica de rotulagem. Para cada evento de crise registrado, a rotulagem marca como positivo (valor 1) os dias situados em uma janela centrada no horizonte de previsão correspondente. Cada janela possui 15 dias de largura, definida pelos parâmetros de tolerância de 7 dias anteriores e 7 dias posteriores ao marco temporal (mais o dia central). Por exemplo, para o horizonte  $y_{90}$ , são marcados os dias entre 97 e 83 dias antes do início da crise; para  $y_{60}$ , entre 74 e 60 dias antes; e para  $y_{30}$ , entre 44 e 30 dias antes. Essa estratégia garante que o modelo aprenda o padrão climático característico de cada antecedência específica, em vez de depender de um único dia isolado ou de misturar sinais de diferentes horizontes. Dias afastados de qualquer janela de pré-crise recebem rótulo 0.

A aplicação dessa lógica aos três eventos documentados resultou em exatamente 45 dias positivos por horizonte (15 dias  $\times$  3 eventos). Cabe destacar que, em virtude dessa estratégia, o sinal de pré-crise localiza-se temporalmente antes do início efetivo da crise: para o evento de 2014-2015, por exemplo, os dias marcados como positivos no horizonte de 90 dias situam-se entre outubro e novembro de 2013. Consequentemente, datas correspondentes ao período da crise em andamento retornam probabilidade próxima de zero, comportamento coerente com o objetivo do modelo de identificar padrões antecedentes, e não a crise consolidada.

Exclusão do período durante a crise. Os registros correspondentes ao intervalo de ocorrência da crise (entre `start_date` e `end_date`) foram explicitamente marcados como ausentes (NaN) e excluídos do conjunto de treinamento. Essa decisão

metodológica se justifica pelo fato de que os dados climáticos observados durante a crise já refletem condições de escassez consolidada, incluí-los no treinamento poderia induzir o modelo a aprender o estado da crise, e não os padrões que a antecedem. Como o objetivo é a previsão (e não a detecção em curso), apenas o sinal pré-evento é relevante.

Resultado da rotulagem. Após a aplicação do processo aos 8.036 dias da série, obteve-se a seguinte distribuição para a variável-alvo principal (y90):

- Dias positivos (pré-crise): 45 (aproximadamente 0,64%)
- Dias negativos (normais): 6.957 (aproximadamente 99,36%)
- Dias excluídos (durante crise): 1.034 (marcados como NaN)

O resultado revela um cenário de forte desbalanceamento de classes, característico de fenômenos climáticos extremos e raros. Esse desequilíbrio é um dado importante da realidade do problema e exigirá tratamento específico durante o treinamento do modelo, conforme detalhado na seção 3.3.5. O *dataset* final, contendo as 22 *features* preditoras e as três variáveis-alvo, foi consolidado no arquivo `inmet_sp_daily_labels.parquet`.

### 3.3.5 Metodologia de Treinamento dos Modelos

A etapa de treinamento corresponde à fase de Modelagem do CRISP-DM. O objetivo é treinar algoritmos de aprendizado de máquina capazes de identificar padrões nas *features* climáticas que precedem crises hídricas. Foram avaliados três algoritmos clássicos de classificação binária, Árvore de Decisão, *Random Forest* e XGBoost, implementados em Python por meio das bibliotecas *Scikit-learn* (PEDREGOSA et al., 2011) e *XGBoost* (CHEN; GUESTRIN, 2016). A implementação está consolidada no *script* `train_model.py`.

Divisão temporal entre treino e teste. A divisão entre os conjuntos de treino e teste respeitou estritamente a ordem cronológica dos dados, sem qualquer tipo de embaralhamento (*shuffle*). Essa escolha é fundamental em séries temporais para evitar *data leakage*, situação em que o modelo teria acesso a informações futuras durante o treinamento, comprometendo a validade da avaliação. A proporção adotada foi de 80% para treino e 20% para teste, resultando na seguinte distribuição cronológica:

- Conjunto de treino: aproximadamente 5.601 dias, cobrindo o período de 2003 a 2020. Contém as crises de 2003–2004 e 2014–2015.
- Conjunto de teste: aproximadamente 1.401 dias, cobrindo o período de 2021 a 2024. Contém a crise de 2021, evento não visto pelo modelo durante o treinamento.

Essa configuração simula realisticamente o uso do sistema em produção: o modelo é treinado com base em histórico passado e avaliado quanto à sua capacidade de antecipar uma crise futura desconhecida.

Algoritmos selecionados. Cada algoritmo foi escolhido com base em uma justificativa metodológica distinta:

- *Árvore de Decisão (Decision Tree)*: algoritmo de referência por sua alta interpretabilidade. Permite visualizar diretamente as regras aprendidas pelo modelo, sendo útil para entender quais variáveis exercem maior influência sobre as previsões.
- *Random Forest*: algoritmo baseado em conjuntos (*ensemble*) de árvores de decisão, treinadas com subamostras aleatórias dos dados (BREIMAN, 2001). É geralmente mais robusto que uma árvore única, reduzindo a variância das previsões. Foi adotado como o modelo principal do estudo.
- *XGBoost (eXtreme Gradient Boosting)*: técnica de *boosting* que constrói árvores sequencialmente, cada uma corrigindo os erros da anterior (CHEN; GUESTRIN, 2016). Costuma atingir desempenho superior em problemas tabulares e foi utilizada como comparação de teto.

Tratamento do desbalanceamento de classes. Como destacado na seção 3.3.4, o *dataset* apresenta forte desbalanceamento, com apenas 0,64% de exemplos positivos. Para mitigar o impacto desse desequilíbrio no aprendizado, foram adotadas duas estratégias complementares:

1. *Ponderação de classes (class weighting)*: nos modelos *Decision Tree* e *Random Forest*, foi aplicado o parâmetro `class_weight='balanced'`, que ajusta automaticamente o peso atribuído a cada classe de forma inversamente proporcional à sua frequência. No XGBoost, foi utilizado o parâmetro

equivalente `scale_pos_weight`, calculado como a razão entre a quantidade de negativos e positivos no conjunto de treino.

2. Otimização do *threshold* de classificação: a primeira execução do *pipeline*, utilizando o *threshold* padrão de 0,5 para a conversão de probabilidades em classes binárias, resultou em F1-score igual a zero em todos os modelos avaliados, ainda que a métrica AUC-ROC indicasse capacidade discriminativa preservada nos modelos. Esse resultado motivou a implementação de uma etapa adicional de otimização: para cada modelo treinado, foi realizada uma busca em grade de *thresholds* entre 0,01 e 0,99 utilizando validação cruzada temporal no conjunto de treino. O *threshold* que maximizou o F1-score médio através dos *folds* foi então aplicado ao conjunto de teste para a avaliação final. Essa abordagem é amplamente recomendada na literatura para problemas com desbalanceamento extremo, nos quais o limiar padrão raramente é atingido pela classe minoritária (HE; GARCIA, 2009).

Validação cruzada temporal. A robustez de cada modelo foi avaliada por meio de validação cruzada com cinco *folds* utilizando a técnica *TimeSeriesSplit*, que respeita a ordem temporal, em cada *fold*, o conjunto de validação é sempre posterior ao conjunto de treino, simulando o comportamento real de previsão. Essa estratégia é considerada o padrão para validação de modelos preditivos em séries temporais (HYNDMAN; ATHANASOPOULOS, 2018).

Métricas de avaliação. Em problemas com forte desbalanceamento, a acurácia simples se mostra inadequada, pois um modelo que sempre prevê a classe majoritária pode atingir 99% de acurácia sem qualquer utilidade prática. Por essa razão, foram adotadas as seguintes métricas:

- F1-score: média harmônica entre precisão e *recall*, métrica principal do estudo. Penaliza tanto os falsos positivos (alarmes falsos) quanto os falsos negativos (crises não detectadas).
- AUC-ROC (*Area Under the Receiver Operating Characteristic Curve*): mede a capacidade do modelo de separar as duas classes independentemente do *threshold* escolhido. Valores próximos de 1,0 indicam alta capacidade discriminativa; 0,5 representa um modelo aleatório.

- Matriz de confusão: visualização detalhada dos acertos e erros do modelo em cada classe, permitindo análise qualitativa dos resultados.
- Importância das *features*: para os modelos baseados em árvores, foi extraída a importância relativa de cada *feature*, permitindo identificar quais variáveis climáticas são mais relevantes para a previsão.

Persistência do modelo final. Ao final do treinamento e avaliação, o melhor modelo (definido como aquele com maior F1-score no conjunto de teste) foi serializado em formato pickle (.pkl) por meio da biblioteca *joblib*, juntamente com o *threshold* otimizado correspondente. Esse arquivo serve como entrada para a aplicação *web* desenvolvida em *Streamlit*, descrita na seção 3.6.

### 3.4 Ferramentas Utilizadas

O método técnico adotado é centrado na modelagem computacional e no desenvolvimento de uma aplicação web dinâmica e interativa. A escolha por essa arquitetura se dá pelo equilíbrio entre complexidade analítica e acessibilidade do produto. O uso de Python é uma linguagem poderosa e amplamente difundida na ciência de dados, é justificado não apenas pela sua sintaxe acessível, mas pela robustez de suas bibliotecas. Foi utilizada para o treinamento dos modelos de Machine Learning juntamente com bibliotecas como: *Numpy* para operações matemáticas, *Matplotlib* e *Seaborn* para visualizações gráficas, *Scikit-learn* para modelagem e avaliação dos dados. Essas facilitaram a manipulação, o treinamento e a avaliação de modelos preditivos e possibilitaram a criação de um modelo capaz de auxiliar nas previsões de crises hídricas em São Paulo.

A aplicação foi construída em camadas: uma de coleta e tratamento de dados, responsável pela aquisição de informações climáticas de fontes confiáveis; uma de inteligência, onde algoritmos como Random Forest, XGBoost e árvores de decisão foram treinados para antecipar situações de escassez; e uma de visualização, voltada à exibição dos resultados por meio de mapas, gráficos e indicadores.

A interface web foi desenvolvida com o framework *Streamlit*, biblioteca Python voltada à criação de aplicações de dados interativas. A escolha do *Streamlit*, em substituição a alternativas como o Django inicialmente consideradas, fundamenta-se em três fatores: a integração direta e nativa com os modelos de aprendizado de máquina treinados em Python, dispensando camadas intermediárias de comunicação;

a agilidade no desenvolvimento de interfaces analíticas, com componentes prontos para gráficos, controles e indicadores; e o alinhamento ao escopo do trabalho, que prioriza a acessibilidade e a clareza na apresentação dos resultados em detrimento de funcionalidades de um framework web completo. Essa decisão favorece o objetivo de democratizar o acesso à ferramenta preditiva, beneficiando desde instituições acadêmicas até gestores públicos.

### **3.5 Modelo EAP do projeto**

No que diz respeito à organização deste trabalho, a utilização de um modelo de Estrutura Analítica do Projeto (EAP) é essencial para assegurar uma organização coerente e integrada das várias fases do estudo. Considerando a complexidade envolvida no monitoramento e na análise de variáveis climáticas, como precipitação, temperatura, umidade e pressão atmosférica, a EAP possibilita a divisão do projeto em componentes distintos e administráveis, facilitando o planejamento, a execução e o controle das ações. Ao organizar as atividades em macroetapas interconectadas, o modelo proporciona uma visão integrada do fluxo de trabalho efetivamente desenvolvido:

#### **1. Iniciação do Projeto**

- 1.1. Definição do objetivo
- 1.2. Identificação dos stakeholders
- 1.3. Definição do escopo

- 1.4. Planejamento do cronograma

#### **2. Levantamento e Coleta de Dados**

- 2.1. Identificação das crises hídricas ocorridas em São Paulo
- 2.2. Definição das variáveis climáticas
  - 2.2.1. Precipitação
  - 2.2.2. Temperatura (média, máxima e mínima)
  - 2.2.3. Umidade relativa
  - 2.2.4. Pressão atmosférica
  - 2.2.5. Velocidade do vento e rajada máxima
  - 2.2.6. Radiação global
- 2.3. Fonte de dados
  - 2.3.1. INMET (Instituto Nacional de Meteorologia)

### **3. Processamento e Preparação dos Dados**

- 3.1. Coleta dos arquivos históricos do INMET
- 3.2. Limpeza e padronização dos registros
- 3.3. Engenharia de features (precipitação acumulada, sequências secas, médias móveis e SPI aproximado)
- 3.4. Rotulagem de pré-evento
- 3.5. Consolidação do dataset final

### **4. Modelagem Preditiva**

- 4.1. Definição da tarefa de predição (classificação binária de pré-crise por horizonte)
- 4.2. Seleção de modelos
  - 4.2.1. Árvore de Decisão
  - 4.2.2. Random Forest
  - 4.2.3. XGBoost
- 4.3. Tratamento do desbalanceamento de classes
- 4.4. Treinamento dos modelos
- 4.5. Validação cruzada temporal
- 4.6. Otimização de *threshold*
- 4.7. Avaliação por métricas (F1-score e AUC-ROC)

### **5. Desenvolvimento da Interface**

- 5.1. Definição dos requisitos da interface
- 5.2. Desenvolvimento da aplicação em Streamlit
- 5.3. Integração com os modelos treinados

### **6. Análise dos Resultados**

- 6.1. Avaliação sobre crise não vista no treino (2021)
- 6.2. Interpretação das variáveis de maior contribuição

### **7. Documentação e Divulgação**

- 7.1. Relatório final do projeto
- 7.2. Geração de visualizações (gráficos e indicadores)
- 7.3. Apresentação do modelo e da ferramenta

### **8. Encerramento do Projeto**

- 8.1. Consolidação das lições aprendidas
- 8.2. Proposta de melhorias futuras

### 8.3. Encerramento formal

## 3.6 Casos de Uso da Aplicação Web e Design Prévios

Esta seção apresenta a concepção inicial de interação dos usuários com o sistema, elaborada durante a fase de planejamento do projeto. No âmbito deste estudo, o desenvolvimento de uma aplicação web intuitiva e de fácil acesso é fundamental para garantir a democratização do acesso aos resultados e apoiar a tomada de decisões baseada em dados. Para isso, adotou-se uma metodologia centrada no usuário, priorizando a clareza visual, a facilidade de uso e a exibição interativa de índices de risco hídrico. Cabe ressaltar que os casos de uso descritos a seguir representam o design conceitual original, contemplando funcionalidades como autenticação e histórico de análises. A implementação final, descrita na seção 3.6.7, adotou uma arquitetura simplificada, alinhada ao escopo e ao prazo do trabalho.

### 3.6.1 Caso uso de acesso

O caso de uso de login, conforme ilustrado na Figura 2, proporciona ao usuário comum uma sequência de passos para interagir efetivamente com o sistema. Após realizar o cadastro no sistema, o usuário pode proceder com o login e, consequentemente, acessar todas as funcionalidades disponíveis. Dentro do sistema, ele possui a capacidade de visualizar o histórico e realizar novas análises.

Figura 2 – Caso de Uso - Acesso



Fonte: Elaborado pelos autores (2025)

### 3.6.2 Modelo da página de login

Por conseguinte, apresenta-se o modelo de login do caso de uso anteriormente citado. A figura 3 demonstra a dinâmica apresentada ao usuário

Figura 3 – Modelo da Página de Login

**Login**

Usuário ou Email

Senha

**Iniciar Sessão**

[Cadastro](#)

[Visualização de Histórico](#)


Fonte: Elaborado pelos autores (2025)

### 3.6.3 Caso de uso – criação de análise

O caso de uso da criação de análise, conforme ilustrado na Figura 4, demonstra ao usuário comum uma sequência de passos ao interagir com a criação de uma nova análise relacionada a crises hídricas. Inicialmente o usuário necessitará inserir os

dados, e a aplicação será responsável por gerar os resultados correspondentes na tela de resultados

Figura 4 – Tela de Criação de Análise



Fonte: Elaborado pelos autores (2025)

### 3.6.4 Modelo página de criação de análise

A seguir a figura 5 demonstra o modelo da página de criação de análise para o usuário final.

Figura 5 – Modelo da Página de Criação de Análise

## Nova Análise – Dados

Iniciar Nova Análise

OU

Inserir Arquivo:

Escolher arquivo

Escolher arquivo

Entrar com Dados Manualmente


Mapear Arquivo

Fonte: Elaborado pelos autores (2025)

### 3.6.5 Caso de uso – resultados da análise

O caso de uso dos resultados da análise demonstrados na figura 6 buscam elucidar a dinâmica de passos ao interagir com a página dos resultados da análise. O usuário poderá ter a opção de baixar o PDF da análise, terá acesso aos erros (se houverem). Além disso, o usuário poderá visualizar os resultados, relatar melhoria e salvar os dados. No que diz respeito a última opção o usuário deverá ter uma conta cadastrada, se não será necessário a criação de um cadastro.

Figura 6 – Tela de Resultados da Análise



Fonte: Elaborado pelos autores (2025)

### 3.6.6 Modelo de página de resultados da análise

Por fim, a figura 7 elucidada o modelo de página final de Resultados da análise. Demonstrando os campos anteriormente citados

Figura 7 – Modelo de Página de Resultados da Análise



Fonte: Elaborado pelos autores (2025)

### 3.6.7 Implementação final da interface

A aplicação efetivamente desenvolvida adotou uma arquitetura simplificada em relação ao design conceitual inicial, priorizando a entrega das funcionalidades essenciais à previsão de crises hídricas dentro do escopo e do prazo do trabalho. Construída com o framework Streamlit, a interface final é composta por quatro páginas, dispensando os mecanismos de autenticação e de histórico originalmente previstos, sem prejuízo ao objetivo central de disponibilizar previsões acessíveis.

A página inicial (Home) apresenta o índice de risco hídrico para um período e horizonte selecionados pelo usuário, exibindo um indicador visual (gauge) com a classificação do risco em três níveis (baixo, médio e alto), acompanhado de uma frase contextual e das variáveis de maior contribuição para a previsão. A página de Previsão permite ao usuário obter previsões a partir do envio de um arquivo CSV ou da inserção manual de valores climáticos. A página de Visualização disponibiliza as séries temporais históricas das variáveis climáticas, com destaque para os períodos de crise documentados. Por fim, a página Sobre consolida a metodologia, as fontes de dados, os resultados e as limitações do estudo.

### 3.7 Divulgação dos Resultados

Os resultados foram compartilhados por meio de diversos canais, incluindo um relatório técnico abrangente sobre a metodologia, os resultados e as conclusões. Além disso, A pesquisa foi apresentada em mostras científicas com o objetivo de atingir a comunidade acadêmica, entidades governamentais, sociedade civil e público em geral.

## 4 ANÁLISE E RESULTADOS

Esta seção apresenta os resultados das fases de Modelagem e Avaliação do CRISP-DM, descritas na seção 3.3.5. São comparados os três algoritmos (Árvore de Decisão, Random Forest e XGBoost) nos três horizontes de previsão (30, 60 e 90 dias), com foco na capacidade discriminativa, no efeito da otimização do threshold, nas variáveis de maior relevância e nos limites revelados pela avaliação. Reitera-se que a avaliação foi conduzida sobre o conjunto de teste (2021 a 2024), que contém a crise de 2021, evento não visto pelos modelos durante o treinamento.

### 4.1 Desempenho comparativo dos modelos

A Tabela 1 consolida o desempenho dos três algoritmos no conjunto de teste, para cada horizonte, após a otimização do *threshold* descrita na seção 3.3.5.

Tabela 1 - Desempenho dos modelos no conjunto de teste, por horizonte de previsão

| Horizonte | Algoritmo         | Threshold | F1 (teste) | AUC-ROC (teste) | F1 (validação cruzada) |
|-----------|-------------------|-----------|------------|-----------------|------------------------|
| 30 dias   | Árvore de Decisão | 0,01      | 0,000      | 0,489           | 0,000                  |
| 30 dias   | Random Forest     | 0,01      | 0,031      | 0,682           | 0,000                  |
| 30 dias   | XGBoost           | 0,01      | 0,000      | 0,700           | 0,000                  |
| 60 dias   | Árvore de Decisão | 0,01      | 0,000      | 0,700           | 0,000                  |

|         |                   |      |       |       |       |
|---------|-------------------|------|-------|-------|-------|
| 60 dias | Random Forest     | 0,01 | 0,000 | 0,500 | 0,000 |
| 60 dias | XGBoost           | 0,01 | 0,000 | 0,492 | 0,000 |
| 90 dias | Árvore de Decisão | 0,01 | 0,000 | 0,500 | 0,000 |
| 90 dias | Random Forest     | 0,01 | 0,000 | 0,465 | 0,000 |
| 90 dias | XGBoost           | 0,01 | 0,000 | 0,592 | 0,000 |

Fonte: Elaborado pelos autores (2025).

Os resultados evidenciam baixo desempenho preditivo sob a ótica do F1-score, que permaneceu próximo de zero em todas as combinações de algoritmo e horizonte, com exceção do Random Forest no horizonte de 30 dias (F1 de 0,031). Sob a ótica do AUC-ROC, observa-se capacidade discriminativa modesta e concentrada no horizonte mais curto: o XGBoost e o Random Forest de 30 dias alcançaram, respectivamente, 0,700 e 0,682, valores situados na fronteira do que a literatura considera discriminação aceitável (em torno de 0,70). Nos horizontes de 60 e 90 dias, o AUC-ROC aproximou-se de 0,50, patamar equivalente à classificação aleatória, chegando a ficar abaixo desse valor em alguns casos.

O melhor desempenho no horizonte de 30 dias é coerente com a expectativa teórica de que antecedenças menores são mais fáceis de prever, por estarem temporalmente mais próximas do evento. Entretanto, não se observa uma tendência monotônica entre os horizontes, uma vez que o desempenho no horizonte de 60 dias foi inferior ao de 90 dias. Atribui-se essa irregularidade ao reduzido número de exemplos positivos no conjunto de teste (aproximadamente 15 dias, correspondentes à antecedença da crise de 2021), o que torna as estimativas instáveis e desaconselha a interpretação de qualquer gradiente entre os horizontes.

Para fins de implantação na aplicação web, adotou-se, para cada horizonte, o modelo de maior F1 no teste, resultando no Random Forest para o horizonte de 30 dias. Nos horizontes de 60 e 90 dias, em que os valores de F1 foram equivalentes, prevaleceu a Árvore de Decisão.


## 4.2 Efeito da otimização do *threshold*

A primeira execução do pipeline, utilizando o *threshold* padrão de 0,5 para a conversão de probabilidades em classes, resultou em F1-score igual a zero em todos os modelos, ainda que o AUC-ROC indicasse capacidade discriminativa preservada. Esse comportamento é típico de problemas com desbalanceamento extremo, nos quais as probabilidades previstas para a classe minoritária raramente ultrapassam 0,5. Em resposta, implementou-se a busca em grade de *thresholds* (0,01 a 0,99) por validação cruzada temporal, conforme a seção 3.3.5. O *threshold* que maximizou o F1 médio convergiu para o limite inferior da grade (0,01) em todos os horizontes, evidenciando que, mesmo no melhor ponto de operação, as probabilidades atribuídas aos dias de pré-crise são muito baixas. Esse resultado é, em si, um indicador da dificuldade do problema: não há limiar capaz de separar adequadamente as duas classes com os dados disponíveis.

## 4.3 Importância das variáveis

A análise da importância relativa das variáveis (critério de Gini) revelou um padrão coerente do ponto de vista físico, com variação relevante entre os horizontes. Nos horizontes de 60 e 90 dias, a variável de maior peso foi a DRY90\_MAX (maior sequência de dias secos em uma janela de 90 dias), responsável por aproximadamente 66% da importância no modelo de 90 dias, seguida pela média móvel de umidade relativa de 30 dias. Evidenciando o predomínio da variável DRY90\_MAX. Esse resultado reforça a hipótese de que a seca acumulada de longo prazo é o principal precursor das crises hídricas. A Figura 8 ilustra a distribuição da importância relativa das variáveis no modelo de 90 dias.

Figura 8 - Importância relativa das variáveis (Árvore de Decisão, horizonte de 90 dias).



Fonte: Elaborado pelos autores (2025).

Já no horizonte de 30 dias, a variável de maior peso passou a ser a média móvel de pressão atmosférica de 7 dias, seguida da pressão média e do SPI30 aproximado. Interpreta-se essa transição da seguinte forma: em antecedências maiores, predomina o sinal de seca acumulada de longo prazo; em antecedências menores, ganham peso variáveis atmosféricas de curto prazo.

Tabela 2 - Importância das variáveis no modelo de 90 dias (cinco maiores)

| Variável             | DRY90_MAX (maior sequência seca em 90 dias) | URMEAN_MA30 (umidade relativa, média móvel de 30 dias) | TMIN (temperatura mínima) | PRESSAO_MED_MA7 (pressão, média móvel de 7 dias) | TMEAN_MA7 (temperatura, média móvel de 7 dias) |
|----------------------|---------------------------------------------|--------------------------------------------------------|---------------------------|--------------------------------------------------|------------------------------------------------|
| Importância relativa | 0,664                                       | 0,214                                                  | 0,071                     | 0,017                                            | 0,015                                          |


Fonte: Elaborado pelos autores (2025)

#### 4.4 Discussão dos resultados

A leitura conjunta das métricas exige distinguir dois aspectos frequentemente confundidos. O AUC-ROC mede a capacidade de ordenação do modelo, ou seja, a probabilidade de atribuir escore maior a um dia de pré-crise do que a um dia normal; o F1-score mede a capacidade de decisão, isto é, o acerto efetivo quando o modelo precisa classificar cada dia. Os resultados indicam que os modelos, sobretudo no horizonte de 30 dias, possuem capacidade de ordenação modesta, porém superior ao acaso, mas não atingem precisão operacional, dado o F1 próximo de zero. Em termos práticos, o modelo consegue indicar que certos dias são relativamente mais propensos à pré-crise, mas não estabelece um limiar de decisão confiável para emitir alertas sem incorrer em excesso de falsos positivos ou na omissão de eventos reais.

Esse comportamento fica evidente nas matrizes de confusão dos modelos implantados. No horizonte de 30 dias (Figura 9), o Random Forest identificou apenas 2 dos 15 dias de pré-crise do conjunto de teste, ao custo de 111 falsos positivos, o que explica o F1 reduzido (0,031) apesar do AUC-ROC de 0,68.


Figura 9 - Matriz de confusão (Random Forest, horizonte de 30 dias)



Fonte: Elaborado pelos autores (2025).

No horizonte de 90 dias (Figura 10), a Árvore de Decisão não recuperou nenhum dos 15 dias de pré-crise, resultando em F1 nulo. Essas matrizes evidenciam, de forma concreta, a ausência de um limiar de decisão capaz de separar as classes com os dados disponíveis.

Figura 10 - Matriz de confusão (Árvore de Decisão, horizonte de 90 dias)



Fonte: Elaborado pelos autores (2025).

Esse desfecho é atribuível, de forma direta, à escassez de dados: apenas três eventos históricos de crise foram documentados e rotulados, totalizando 45 dias positivos em 8.036 dias de série, dos quais cerca de 15 compõem o conjunto de teste. Trata-se de um teto de desempenho imposto pela natureza rara do fenômeno e pela limitada disponibilidade pública de eventos, e não de uma deficiência da metodologia, que seguiu práticas consolidadas para séries temporais e dados desbalanceados, como a validação temporal, a ponderação de classes e a otimização de *threshold*. Os achados são consistentes com a literatura, que aponta a quantidade de exemplos positivos como fator crítico para a previsão de fenômenos extremos raros (HE; GARCIA, 2009).

Por essa razão, a aplicação web desenvolvida deve ser compreendida como um protótipo funcional que operacionaliza e demonstra a viabilidade da metodologia proposta, e não como uma ferramenta de previsão validada para uso operacional. A contribuição central do trabalho reside na construção de um pipeline completo e reproduzível e na caracterização honesta dos limites da abordagem, o que fundamenta as sugestões de trabalho futuro apresentadas na seção 5.

## 5 CONCLUSÃO

Este trabalho teve como objetivo a construção de uma aplicação web para previsão de crises hídricas no estado de São Paulo, com base em dados climáticos do INMET e em modelos de aprendizado de máquina supervisionado. O objetivo geral foi cumprido: o pipeline completo de coleta, pré-processamento, rotulagem, treinamento e avaliação foi implementado e disponibilizado por meio de um protótipo funcional desenvolvido com o framework Streamlit.

A avaliação dos modelos revelou capacidade discriminativa modesta e concentrada no horizonte de 30 dias, com AUC-ROC de 0,68 para o Random Forest e de 0,70 para o XGBoost nesse horizonte. Nos horizontes de 60 e 90 dias, o AUC-ROC aproximou-se de 0,50, equivalente à classificação aleatória. Em todos os casos, o F1-score permaneceu próximo de zero no conjunto de teste, indicando que os modelos, apesar de apresentarem alguma capacidade de ordenação, não atingiram precisão operacional para a emissão de alertas confiáveis. Esse resultado é atribuído, primariamente, à escassez de dados positivos: apenas três eventos históricos de crise hídrica foram identificados e rotulados, totalizando 45 dias de pré-crise em uma série de 8.036 dias, dos quais aproximadamente 15 compõem o conjunto de teste.

Essa limitação configura um teto de desempenho imposto pela natureza rara do fenômeno e pela escassez de eventos documentados, e não uma deficiência de execução metodológica: o trabalho seguiu práticas consolidadas para séries temporais com desbalanceamento extremo, como a divisão temporal sem embaralhamento, a ponderação de classes, a otimização de *threshold* por validação cruzada e a avaliação por AUC-ROC e F1-score. A identificação desse teto é um resultado relevante por si só, pois delimita o que é, e o que ainda não é, alcançável com dados exclusivamente climáticos: a predição operacional de crises hídricas a partir apenas dessas variáveis mostra-se inviável nas condições atuais de rotulagem, e a superação desse limite depende menos do algoritmo e mais da ampliação e do enriquecimento da base de dados, conforme as direções apresentadas a seguir.

Três direções de trabalho futuro se mostram prioritárias para superar essa limitação. A primeira e mais impactante é a ampliação da base de eventos de crise rotulados, incorporando episódios adicionais de outros sistemas hídricos e de outras regiões, o que forneceria exemplos positivos suficientes para treinar e avaliar modelos

com maior robustez. A segunda é a desagregação dos dados por estação meteorológica, substituindo a agregação global por São Paulo adotada neste trabalho, o que permitiria capturar padrões espaciais relevantes. A terceira é a implementação do Índice Padronizado de Precipitação completo, com ajuste de distribuição gama, em substituição à aproximação por z-score utilizada. Adicionalmente, a incorporação de variáveis hidrológicas diretas, como o volume útil do Sistema Cantareira, representa uma extensão natural do modelo, uma vez que essas variáveis refletem diretamente o estado do sistema de abastecimento.

Em síntese, este trabalho contribui com uma metodologia completa, reproduzível e honestamente avaliada para a previsão de crises hídricas, demonstrando a viabilidade da abordagem e delimitando com precisão suas fronteiras atuais. A disponibilização do pipeline e do protótipo web como recursos abertos favorece a continuidade da pesquisa e a eventual evolução da ferramenta para uso em cenários de apoio à decisão na gestão hídrica.

## REFERÊNCIAS

46% DA POPULAÇÃO GLOBAL vive sem acesso a saneamento básico. ONU News. Disponível em: <https://news.un.org/pt/story/2023/03/1811712>. Acesso em: 6 jun. 2025.

ABCON SINDCON. Crise hídrica: causas, impactos e soluções. Disponível em: <https://abconsindcon.com.br/crise-hidrica-causas-impactos-e-solucoes/>. Acesso em: 6 jun. 2025.

ABES-SP - ASSOCIAÇÃO BRASILEIRA DE ENGENHARIA SANITÁRIA E AMBIENTAL, SEÇÃO SÃO PAULO. Nota técnica sobre as mudanças climáticas e a crise hídrica que afeta o Estado de São Paulo e o país em 2021. São Paulo: ABES-SP, set. 2021. Disponível em: <https://www.abes-sp.org.br/nota-tecnica-da-abes-sp-sobre-as-mudancas-climaticas-e-a-crise-hidrica-que-afeta-o-estado-de-sao-paulo-e-o-pais-em-2021/>. Acesso em: 22 maio 2025.

AHMED, K.; SHAHID, S.; CHUNG, E.-S. Predicting droughts using machine learning algorithms: a case study of Pakistan. *Water Resources Management*, v. 34, n. 10, p. 3251–3270, 2020. Acesso em: 26 abr. 2025.

AGÊNCIA NACIONAL DE ÁGUAS - ANA. Conjuntura dos recursos hídricos no Brasil: informe 2014 - encarte especial sobre a crise hídrica. Brasília: ANA, 2015. Disponível em: <https://www.gov.br/ana/pt-br/centrais-de-conteudos/publicacoes>. Acesso em: 22 maio 2025.

BATISTA, J. D.; FRANCIEL, J.; LENNON, A. Desenvolvimento do sistema integrado de monitoramento e gestão dos recursos hídricos no estado do Tocantins. *Revista Sítio Novo*, v. 9, p. e1671, 14 maio 2025.

BRASIL. Decreto n. 24.643, de 10 de julho de 1934. Código das Águas. Rio de Janeiro: Governo Provisório da República dos Estados Unidos do Brasil, 1934. Disponível em: [https://www.planalto.gov.br/ccivil\\_03/decreto/d24643.htm](https://www.planalto.gov.br/ccivil_03/decreto/d24643.htm). Acesso em: 15 maio 2025.

BRASIL. Lei n. 9.433, de 8 de janeiro de 1997. Política Nacional de Recursos Hídricos. Brasília: Presidência da República, 1997. Disponível em: [http://www.planalto.gov.br/ccivil\\_03/LEIS/L9433.htm](http://www.planalto.gov.br/ccivil_03/LEIS/L9433.htm). Acesso em: 20 maio 2025.

BREIMAN, L. Random forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001. Disponível em: <https://doi.org/10.1023/A:1010933404324>. Acesso em: 22 maio 2025.

CASEMIRO, P. Primeiro mês de 2025 foi o janeiro mais quente da história. G1. Disponível em: <https://g1.globo.com/meio-ambiente/noticia/2025/02/06/primeiro-mes-de-2025-foi-o-janeiro-mais-quente-da-historia.ghtml>. Acesso em: 5 maio 2025.

CHAPMAN, P. et al. CRISP-DM 1.0: step-by-step data mining guide. [S. l.]: SPSS, 2000. Disponível em: <https://www.kde.cs.uni-kassel.de/wp->

<content/uploads/lehre/ws2012-13/kdd/files/CRISPWP-0800.pdf>. Acesso em: 26 maio 2025.

CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. In: PROCEEDINGS OF THE 22ND ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING. San Francisco: ACM, 2016. p. 785–794. Disponível em: <https://doi.org/10.1145/2939672.2939785>. Acesso em: 22 maio 2025.

INSTITUTO DE PESQUISA ECONÔMICA APLICADA - IPEA. O Brasil precisa priorizar seu recurso mais precioso: a água. Centro de Pesquisa em Ciência, Tecnologia e Sociedade. Disponível em: <https://www.ipea.gov.br/cts/pt/central-de-conteudo/noticias/noticias/300-o-brasil-precisa-priorizar-seu-recurso-mais-precioso-a-agua>. Acesso em: 6 jun. 2025.

FRICH, P.; ALEXANDER, L. V.; DELLA-MARTA, P.; GLEASON, B.; HAYLOCK, M.; KLEIN TANK, A. M. G.; PETERSON, T. Observed coherent changes in climatic extremes during the second half of the twentieth century. *Climate Research*, v. 19, p. 193–212, 2002. Disponível em: <https://doi.org/10.3354/cr019193>. Acesso em: 22 maio 2025.

GALIZONI, F. M.; RIBEIRO, E. M. Bem comum e normas costumeiras: a ética das águas em comunidades rurais de Minas Gerais. *Ambiente & Sociedade*, v. 14, p. 77–94, 2011. Disponível em: <http://dx.doi.org/10.1590/S1414-753X2011000100005>. Acesso em: 22 maio 2025.

GALVÃO, J.; BERMANN, C. Crise hídrica e energia: conflitos no uso múltiplo das águas. *Estudos Avançados*, v. 29, n. 84, p. 43–68, 2015. Disponível em: <https://doi.org/10.1590/S0103-40142015000200004>. Acesso em: 22 maio 2025.

HE, H.; GARCIA, E. A. Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, v. 21, n. 9, p. 1263–1284, 2009. Disponível em: <https://doi.org/10.1109/TKDE.2008.239>. Acesso em: 22 maio 2025.

HYNDMAN, R. J.; ATHANASOPOULOS, G. Forecasting: principles and practice. 2. ed. Melbourne: OTexts, 2018. Disponível em: <https://otexts.com/fpp2/>. Acesso em: 22 maio 2025.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA - IBGE. Projeções da população: população por sexo e idade simples 2000–2025. Disponível em: <https://www.ibge.gov.br/estatisticas/sociais/populacao/9109-projecao-da-populacao.html?edicao=41053>. Acesso em: 21 maio 2025.

INSTITUTO NACIONAL DE METEOROLOGIA - INMET. Ano de 2024 é o mais quente no Brasil desde 1961. Disponível em: <https://portal.inmet.gov.br/noticias/2024-é-o-ano-mais-quente-da-série-histórica-no-brasil>. Acesso em: 17 abr. 2025.

INTERGOVERNMENTAL PANEL ON CLIMATE CHANGE - IPCC. Climate change 2014: synthesis report. Contribution of Working Groups I, II and III to the Fifth Assessment Report of the Intergovernmental Panel on Climate Change. Geneva: IPCC, 2014.

MARENGO, J. A.; NOBRE, C. A.; SELUCHI, M. E.; CUARTAS, A.; ALVES, L. M.; MENDIONDO, E. M.; OBREGÓN, G.; SAMPAIO, G. A seca e a crise hídrica de 2014–2015 em São Paulo. *Revista USP*, São Paulo, n. 106, p. 31–44, 2015. Disponível em: <https://revistas.usp.br/revusp/article/view/110101>. Acesso em: 22 maio 2025.

McKEE, T. B.; DOESKEN, N. J.; KLEIST, J. The relationship of drought frequency and duration to time scales. In: AMS CONFERENCE ON APPLIED CLIMATOLOGY, 1993. Acesso em: 26 abr. 2025.

MITCHELL, T. M. Machine learning. New York: McGraw-Hill, 1997.

PAPA FRANCISCO. Laudato Si': louvado sejas: sobre o cuidado da casa comum. São Paulo: Paulus; Loyola, 2015. 141 p.

PEDREGOSA, F. et al. *Scikit-learn: machine learning in Python*. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Disponível em: <https://jmlr.org/papers/v12/pedregosa11a.html>. Acesso em: 22 maio 2025.

SCHER, S. Toward data-driven weather and climate forecasting: approximating a simple general circulation model with deep learning. *Geophysical Research Letters*, v. 45, n. 22, p. 12616–12622, 2018. Disponível em: <https://doi.org/10.1029/2018GL080704>. Acesso em: 22 maio 2025.

SCHER, S.; MESSORI, G. Weather and climate forecasting with neural networks: using general circulation models (GCMs) with different complexity as a study ground. *Geoscientific Model Development*, v. 12, n. 7, p. 2797–2809, 2019. Disponível em: <https://doi.org/10.5194/gmd-12-2797-2019>. Acesso em: 22 maio 2025.

SELBORNE, L. A ética do uso da água doce: um levantamento. Brasília: Unesco, 2001. 32 p.

SHEARER, C. *The CRISP-DM model: the new blueprint for data mining*. *Journal of Data Warehousing*, v. 5, n. 4, p. 13–22, 2000. Disponível em: <https://www.scirp.org/reference/ReferencesPapers?ReferenceID=1592780>. Acesso em: 26 maio 2025.

SILVA, D. F.; OLIVEIRA, R. A.; ALMEIDA, F. S. Desenvolvimento de plataforma web para visualização de dados hidrometeorológicos. *Revista Brasileira de Geografia Física*, v. 15, n. 2, p. 234–248, 2022. Acesso em: 26 abr. 2025.

SILVA, E. F. V. da. Uso da ciência de dados através da metodologia CRISP-DM para análise da percepção de pesquisadores e profissionais acerca das medidas de transição da economia linear para circular. 2022. 123 f. Dissertação (Mestrado em

Engenharia de Produção) - Universidade Federal de Pernambuco, Recife, 2022. Disponível em: <https://repositorio.ufpe.br/handle/123456789/58178>. Acesso em: 26 maio 2025.

TUNDISI, J. G. Recursos hídricos no futuro: problemas e soluções. *Estudos Avançados*, v. 22, n. 63, p. 7–16, 2008. Disponível em: <https://doi.org/10.1590/S0103-40142008000200002>. Acesso em: 22 maio 2025.

WELLS, N.; GODDARD, S.; HAYES, M. J. A self-calibrating Palmer Drought Severity Index. *Journal of Climate*, v. 17, n. 12, p. 2335–2351, 2004. Acesso em: 27 abr. 2025.

WEYN, J. A.; DURRAN, D. R.; CARUANA, R. Can machines learn to predict weather? Using deep learning to predict gridded 500-hPa geopotential height from historical weather data. *Journal of Advances in Modeling Earth Systems*, v. 11, n. 8, p. 2680–2693, ago. 2019.

WORLD BANK. Data-driven decision making for water resources management. Disponível em: <https://www.worldbank.org>. Acesso em: 26 abr. 2025.

YASEEN, Z. M. et al. Advanced artificial intelligence models for drought forecasting: a review. *Environmental Modelling & Software*, v. 136, 104964, 2021. Acesso em: 28 abr. 2025.